

虚拟内存：系统

主要内容

- 简单内存系统示例
- 案例研究: Core i7/Linux 内存系统
- Linux内存映射

符号回顾

■ 基本参数 (Basic Parameters)

- $N = 2^n$: 虚拟地址空间中可寻址的地址数量
- $M = 2^m$: 物理地址空间中可寻址的地址数量
- $P = 2^p$: 页面大小 (bytes)

■ 虚拟地址 (VA, Virtual Address) 的组成

- TLBI (TLB Index) : TLB 索引
- TLBT (TLB Tag) : TLB 标签
- VPO (Virtual Page Offset) : 虚拟页偏移
- VPN (Virtual Page Number) : 虚拟页号

■ 物理地址 (PA, Physical Address) 的组成

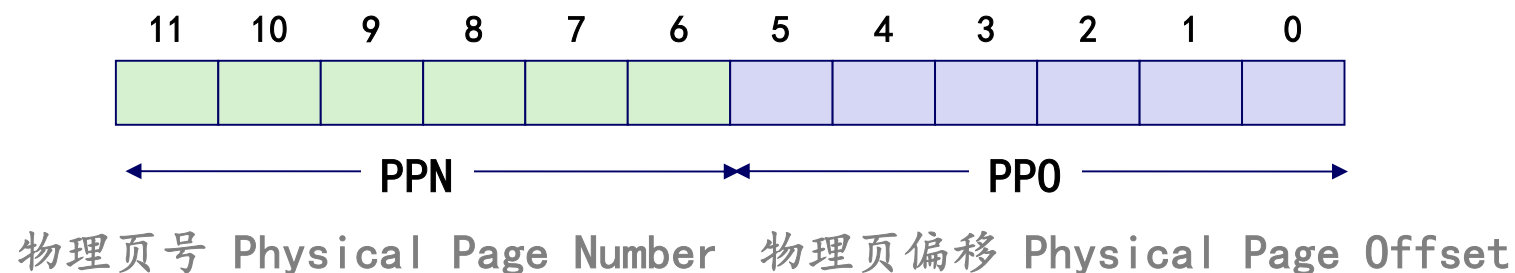
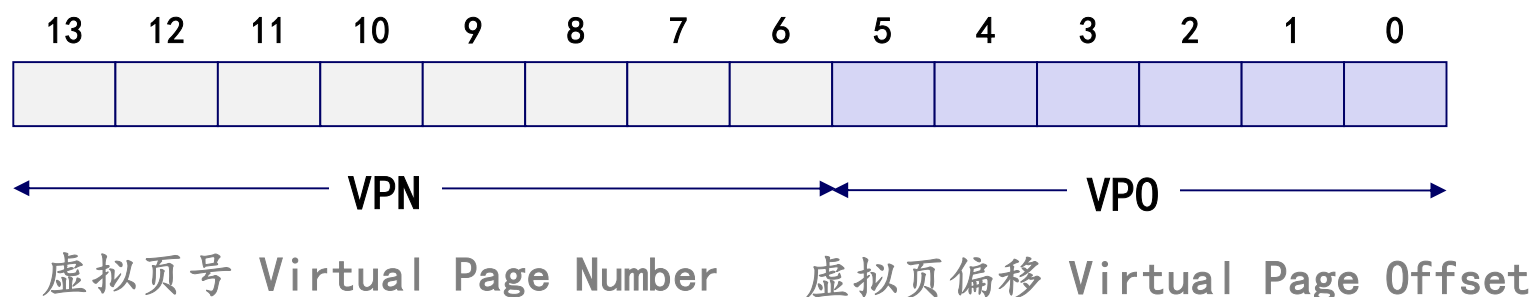
- PPO (Physical Page Offset) : 物理页偏移, 与虚拟页偏移 VPO 完全相同
- PPN (Physical Page Number) : 物理页号
- CO: Byte offset within cache line, 偏移
- CI: Cache index
- CT: Cache tag

端到端的地址翻译：一个简单的例子

- 示例运行在一个有TLB和L1 d-cache的小系统上，为了简化，假设：
 - 存储器是按字节寻址的。
 - 存储器访问是针对1字节的字的
 - 虚拟地址是14位长的 ($n=14$)。
 - 物理地址是12位长的 ($m=12$)。
 - 页面大小是64字节 ($P=64$)。
 - TLB是四路组相联的，总共有16个条目
 - L1 d-cache是物理寻址、直接映射的，行大小为4字节，总共有16组。


端到端的地址翻译: 一个简单的例子

- 这里展示了虚拟地址和物理地址的格式。
- 因为每个页面是 $2^6 = 64$ 字节，所以虚拟地址和物理地址的低6位分别作为VP0和PP0。虚拟地址的高8位作为VPN。物理地址的高6位作为PPN。




这个示例小存储器系统的一个快照

- 包括TLB (a)、页表的一部分 (b)，高速缓存 (c)。
- 在TLB和高速缓存的图上面，我们还展示了访问这些设备时硬件是如何划分虚拟地址和物理地址的位的。



| Set | Tag | PPN | Valid | Tag | PPN | Valid | Tag | PPN | Valid | Tag | PPN | Valid |
|-----|-----|-----|-------|-----|-----|-------|-----|-----|-------|-----|-----|-------|
| 0 | 03 | - | 0 | 09 | 0D | 1 | 00 | - | 0 | 07 | 02 | 1 |
| 1 | 03 | 2D | 1 | 02 | - | 0 | 04 | - | 0 | 0A | - | 0 |
| 2 | 02 | - | 0 | 08 | - | 0 | 06 | - | 0 | 03 | - | 0 |
| 3 | 07 | - | 0 | 03 | 0D | 1 | 0A | 34 | 1 | 02 | - | 0 |

a) TLB: 四组，16个条目，四路组相连



| Idx | Tag | Valid | B0 | B1 | B2 | B3 |
|-----|-----|-------|----|----|----|----|
| 0 | 19 | 1 | 99 | 11 | 23 | 11 |
| 1 | 15 | 0 | - | - | - | - |
| 2 | 1B | 1 | 00 | 02 | 04 | 08 |
| 3 | 36 | 0 | - | - | - | - |
| 4 | 32 | 1 | 43 | 6D | 8F | 09 |
| 5 | 0D | 1 | 36 | 72 | F0 | 1D |
| 6 | 31 | 0 | - | - | - | - |
| 7 | 16 | 1 | 11 | C2 | DF | 03 |

| Idx | Tag | Valid | B0 | B1 | B2 | B3 |
|-----|-----|-------|----|----|----|----|
| 8 | 24 | 1 | 3A | 00 | 51 | 89 |
| 9 | 2D | 0 | - | - | - | - |
| A | 2D | 1 | 93 | 15 | DA | 3B |
| B | 0B | 0 | - | - | - | - |
| C | 12 | 0 | - | - | - | - |
| D | 16 | 1 | 04 | 96 | 34 | 15 |
| E | 13 | 1 | 83 | 77 | 1B | D3 |
| F | 14 | 0 | - | - | - | - |


c) 高速缓存: 16个组，4字节的块，直接映射

| VPN | PPN | Valid |
|-----|-----|-------|
| 00 | 28 | 1 |
| 01 | - | 0 |
| 02 | 33 | 1 |
| 03 | 02 | 1 |
| 04 | - | 0 |
| 05 | 16 | 1 |
| 06 | - | 0 |
| 07 | - | 0 |
| 08 | 13 | 1 |
| 09 | 17 | 1 |
| 0A | 09 | 1 |
| 0B | - | 0 |
| 0C | - | 0 |
| 0D | 2D | 1 |
| 0E | 11 | 1 |
| 0F | 0D | 1 |

b) 页表，只展示了前16个PTE

1. 示例小内存系统中的TLB

- TLB是利用 VPN 的位进行虚拟寻址的。
- TLB有4个组，所以 VPN 的低2位就作为组索引(TLBI)，VPN中剩下的高6位作为标记(TLBT)，用来区别可能映射到同一个 TLB 组的不同的VPN。



| Set | Tag | PPN | Valid | Tag | PPN | Valid | Tag | PPN | Valid | Tag | PPN | Valid |
|-----|-----|-----|-------|-----|-----|-------|-----|-----|-------|-----|-----|-------|
| 0 | 03 | — | 0 | 09 | 0D | 1 | 00 | — | 0 | 07 | 02 | 1 |
| 1 | 03 | 2D | 1 | 02 | — | 0 | 04 | — | 0 | 0A | — | 0 |
| 2 | 02 | — | 0 | 08 | — | 0 | 06 | — | 0 | 03 | — | 0 |
| 3 | 07 | — | 0 | 03 | 0D | 1 | 0A | 34 | 1 | 02 | — | 0 |

2. 示例小内存系统中的页表

- 页表是一个单级设计，一共有256个页表条目 (PTE)。只列出了开头16个。
- 每个无效PTE的PPN都用一个破折号来表示。


| <i>VPN</i> | <i>PPN</i> | <i>Valid</i> |
|------------|------------|--------------|
| 00 | 28 | 1 |
| 01 | — | 0 |
| 02 | 33 | 1 |
| 03 | 02 | 1 |
| 04 | — | 0 |
| 05 | 16 | 1 |
| 06 | — | 0 |
| 07 | — | 0 |

| <i>VPN</i> | <i>PPN</i> | <i>Valid</i> |
|------------|------------|--------------|
| 08 | 13 | 1 |
| 09 | 17 | 1 |
| 0A | 09 | 1 |
| 0B | — | 0 |
| 0C | — | 0 |
| 0D | 2D | 1 |
| 0E | 11 | 1 |
| 0F | 0D | 1 |

b) 页表，只展示了前16个PTE

3. 示例小内存系统中的高速缓存(L1)

- 直接映射的缓存
- 通过物理地址中的字段来寻址
- 每个块都是4字节，所以物理地址底2位作为块偏移
- 一共16组，4位表示组索引 (CI)，6位表示标记 (CT)



| Idx | Tag | Valid | B0 | B1 | B2 | B3 |
|-----|-----|-------|----|----|----|----|
| 0 | 19 | 1 | 99 | 11 | 23 | 11 |
| 1 | 15 | 0 | — | — | — | — |
| 2 | 1B | 1 | 00 | 02 | 04 | 08 |
| 3 | 36 | 0 | — | — | — | — |
| 4 | 32 | 1 | 43 | 6D | 8F | 09 |
| 5 | 0D | 1 | 36 | 72 | F0 | 1D |
| 6 | 31 | 0 | — | — | — | — |
| 7 | 16 | 1 | 11 | C2 | DF | 03 |

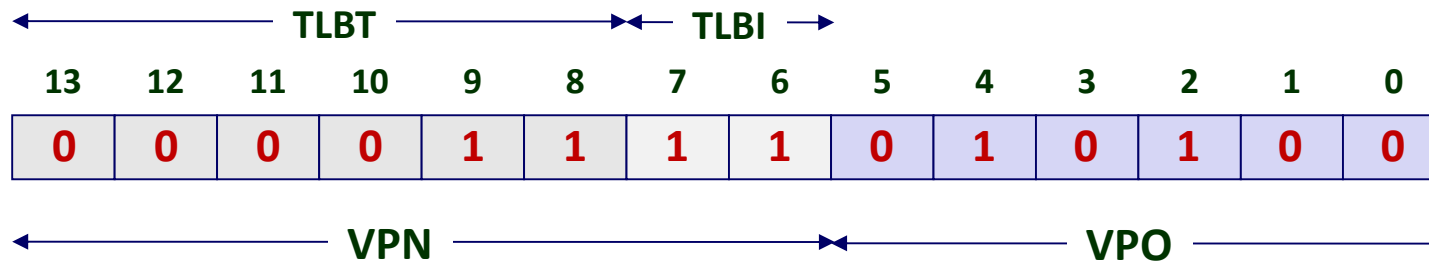
| Idx | Tag | Valid | B0 | B1 | B2 | B3 |
|-----|-----|-------|----|----|----|----|
| 8 | 24 | 1 | 3A | 00 | 51 | 89 |
| 9 | 2D | 0 | — | — | — | — |
| A | 2D | 1 | 93 | 15 | DA | 3B |
| B | 0B | 0 | — | — | — | — |
| C | 12 | 0 | — | — | — | — |
| D | 16 | 1 | 04 | 96 | 34 | 15 |
| E | 13 | 1 | 83 | 77 | 1B | D3 |
| F | 14 | 0 | — | — | — | — |

地址翻译例子#1

虚拟地址: 0x03D4

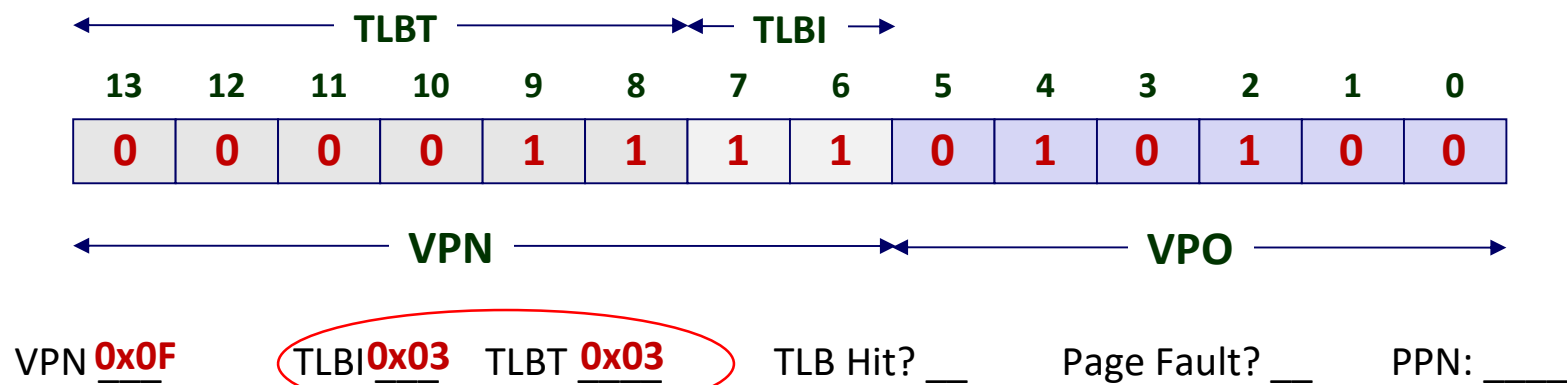
地址翻译例子#1

虚拟地址: 0x03D4:




地址翻译例子#1

虚拟地址: 0x03D4:




1. 示例小内存系统中的TLB

- TLB是利用 VPN 的位进行虚拟寻址的。
- TLB有4个组，所以 VPN 的低2位就作为组索引(TLBI)，VPN中剩下的高6位作为标记(TLBT)，用来区别可能映射到同一个 TLB 组的不同的VPN。




地址翻译例子#1

虚拟地址: 0x03D4:




地址翻译例子#1

虚拟地址: 0x03D4:




物理地址: 0x354




地址翻译例子#1

虚拟地址: 0x03D4:

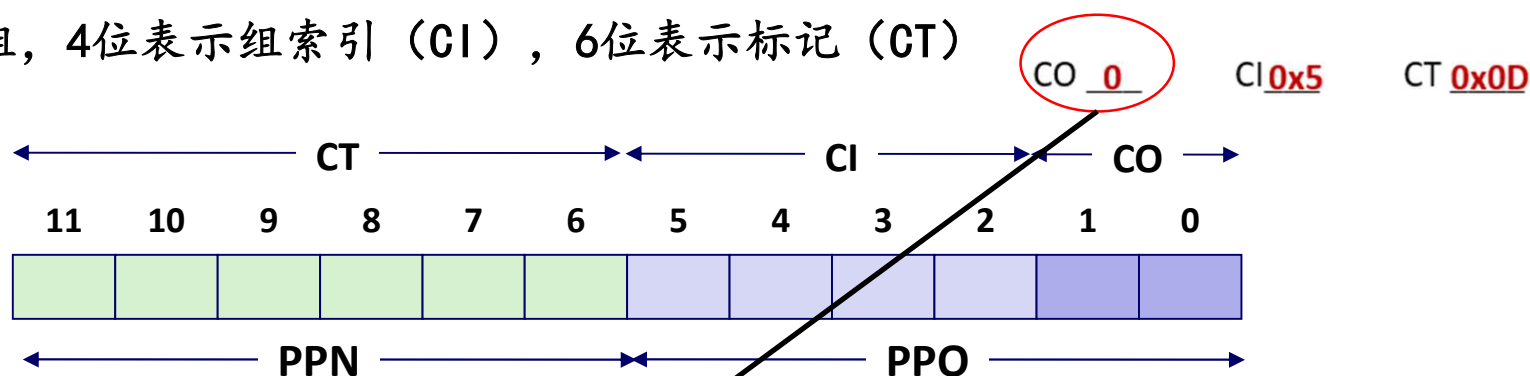


物理地址:



3. 示例的小内存系统中的高速缓存(L1)

- 直接映射的缓存
- 通过物理地址中的字段来寻址
- 每个块都是4字节，所以物理地址底2位作为块偏移
- 一共16组，4位表示组索引（CI），6位表示标记（CT）




| Idx | Tag | Valid | B0 | B1 | B2 | B3 |
|-----|-----|-------|----|----|----|----|
| 0 | 19 | 1 | 99 | 11 | 23 | 11 |
| 1 | 15 | 0 | — | — | — | — |
| 2 | 1B | 1 | 00 | 02 | 04 | 08 |
| 3 | 36 | 0 | — | — | — | — |
| 4 | 32 | 1 | 43 | 6D | 8F | 09 |
| 5 | 0D | 1 | 36 | 72 | F0 | 1D |
| 6 | 31 | 0 | — | — | — | — |
| 7 | 16 | 1 | 11 | C2 | DF | 03 |


| Idx | Tag | Valid | B0 | B1 | B2 | B3 |
|-----|-----|-------|----|----|----|----|
| 8 | 24 | 1 | 3A | 00 | 51 | 89 |
| 9 | 2D | 0 | — | — | — | — |
| A | 2D | 1 | 93 | 15 | DA | 3B |
| B | 0B | 0 | — | — | — | — |
| C | 12 | 0 | — | — | — | — |
| D | 16 | 1 | 04 | 96 | 34 | 15 |
| E | 13 | 1 | 83 | 77 | 1B | D3 |
| F | 14 | 0 | — | — | — | — |

地址翻译例子#1

虚拟地址: 0x03D4:



物理地址:

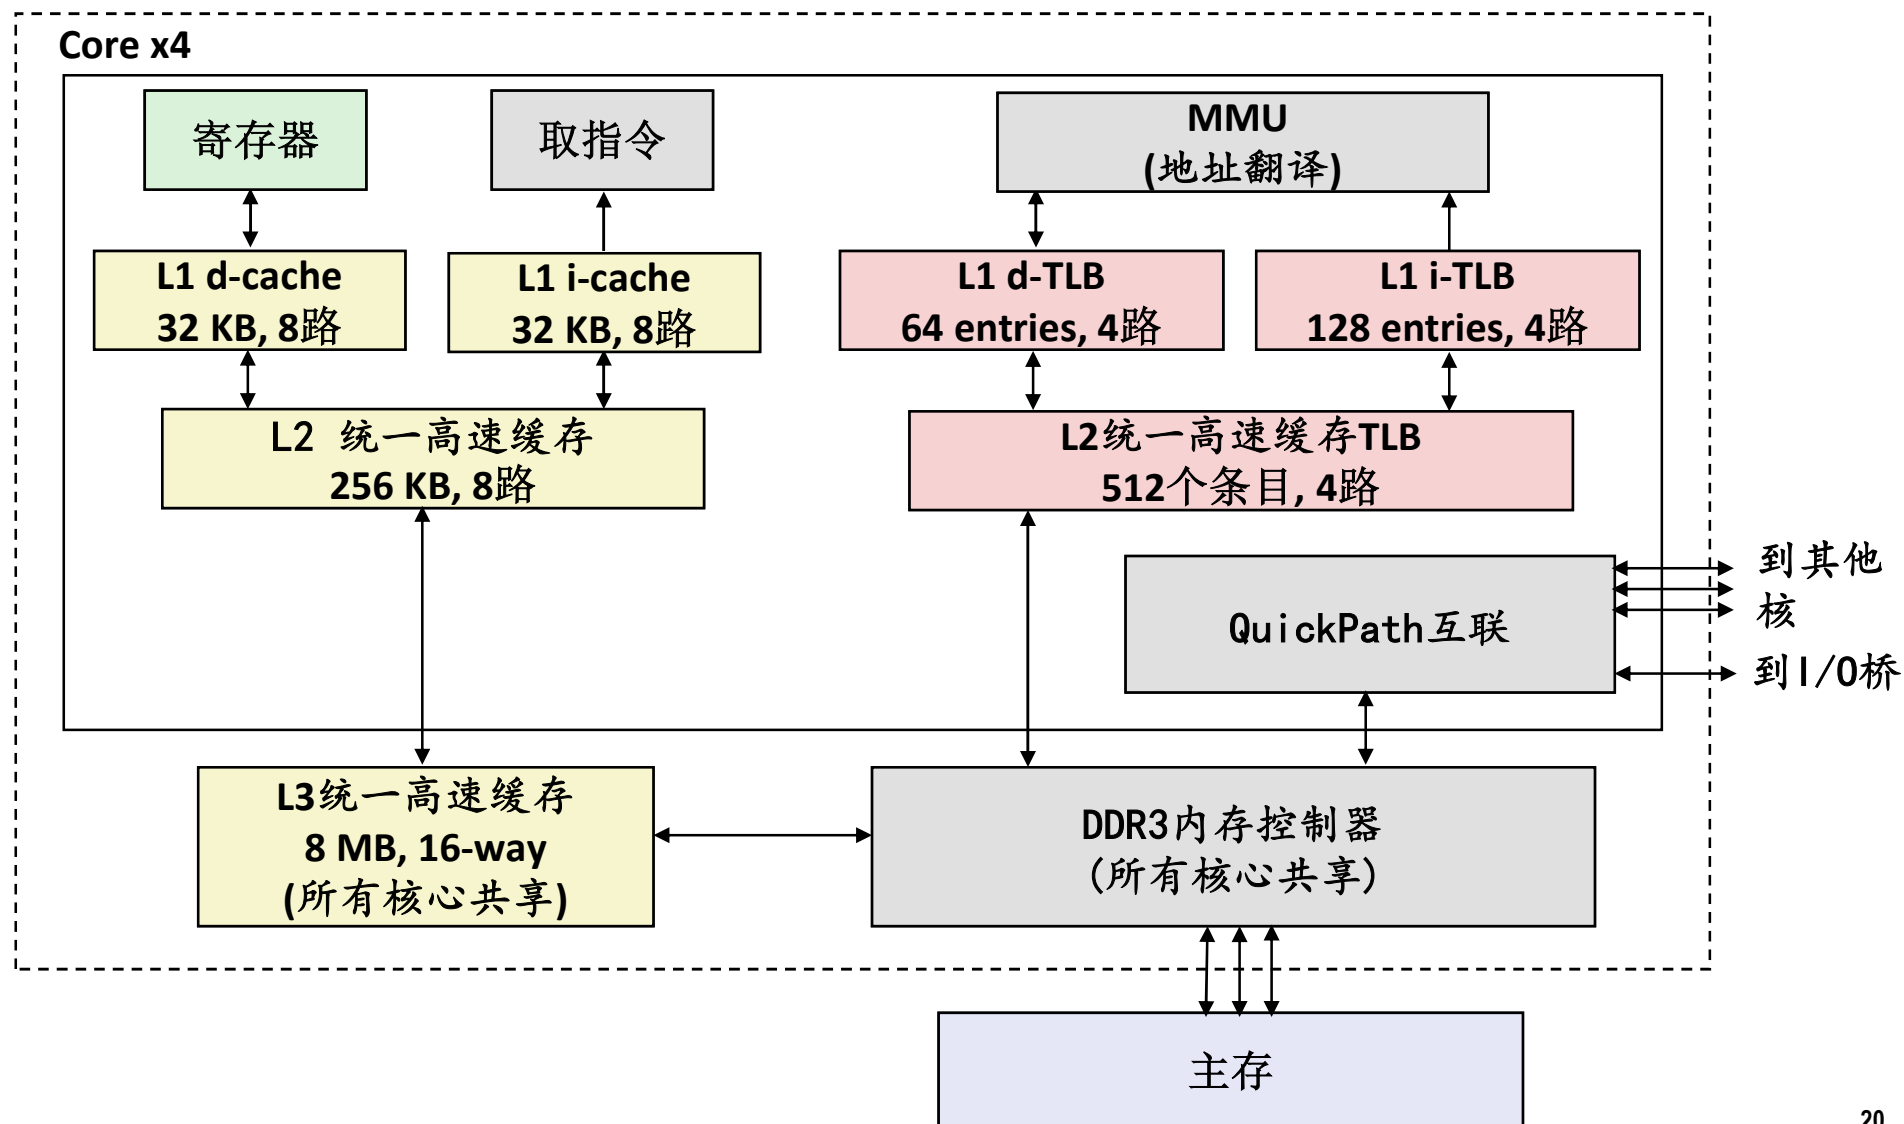


主要内容

- 简单内存系统示例
- 案例研究：Core i7/Linux 内存系统
- Linux内存映射

Intel Core i7 内存系统

处理器封装



符号回顾

■ 基本参数 (Basic Parameters)

- $N = 2^n$: 虚拟地址空间中可寻址的地址数量
- $M = 2^m$: 物理地址空间中可寻址的地址数量
- $P = 2^p$: 页面大小 (bytes)

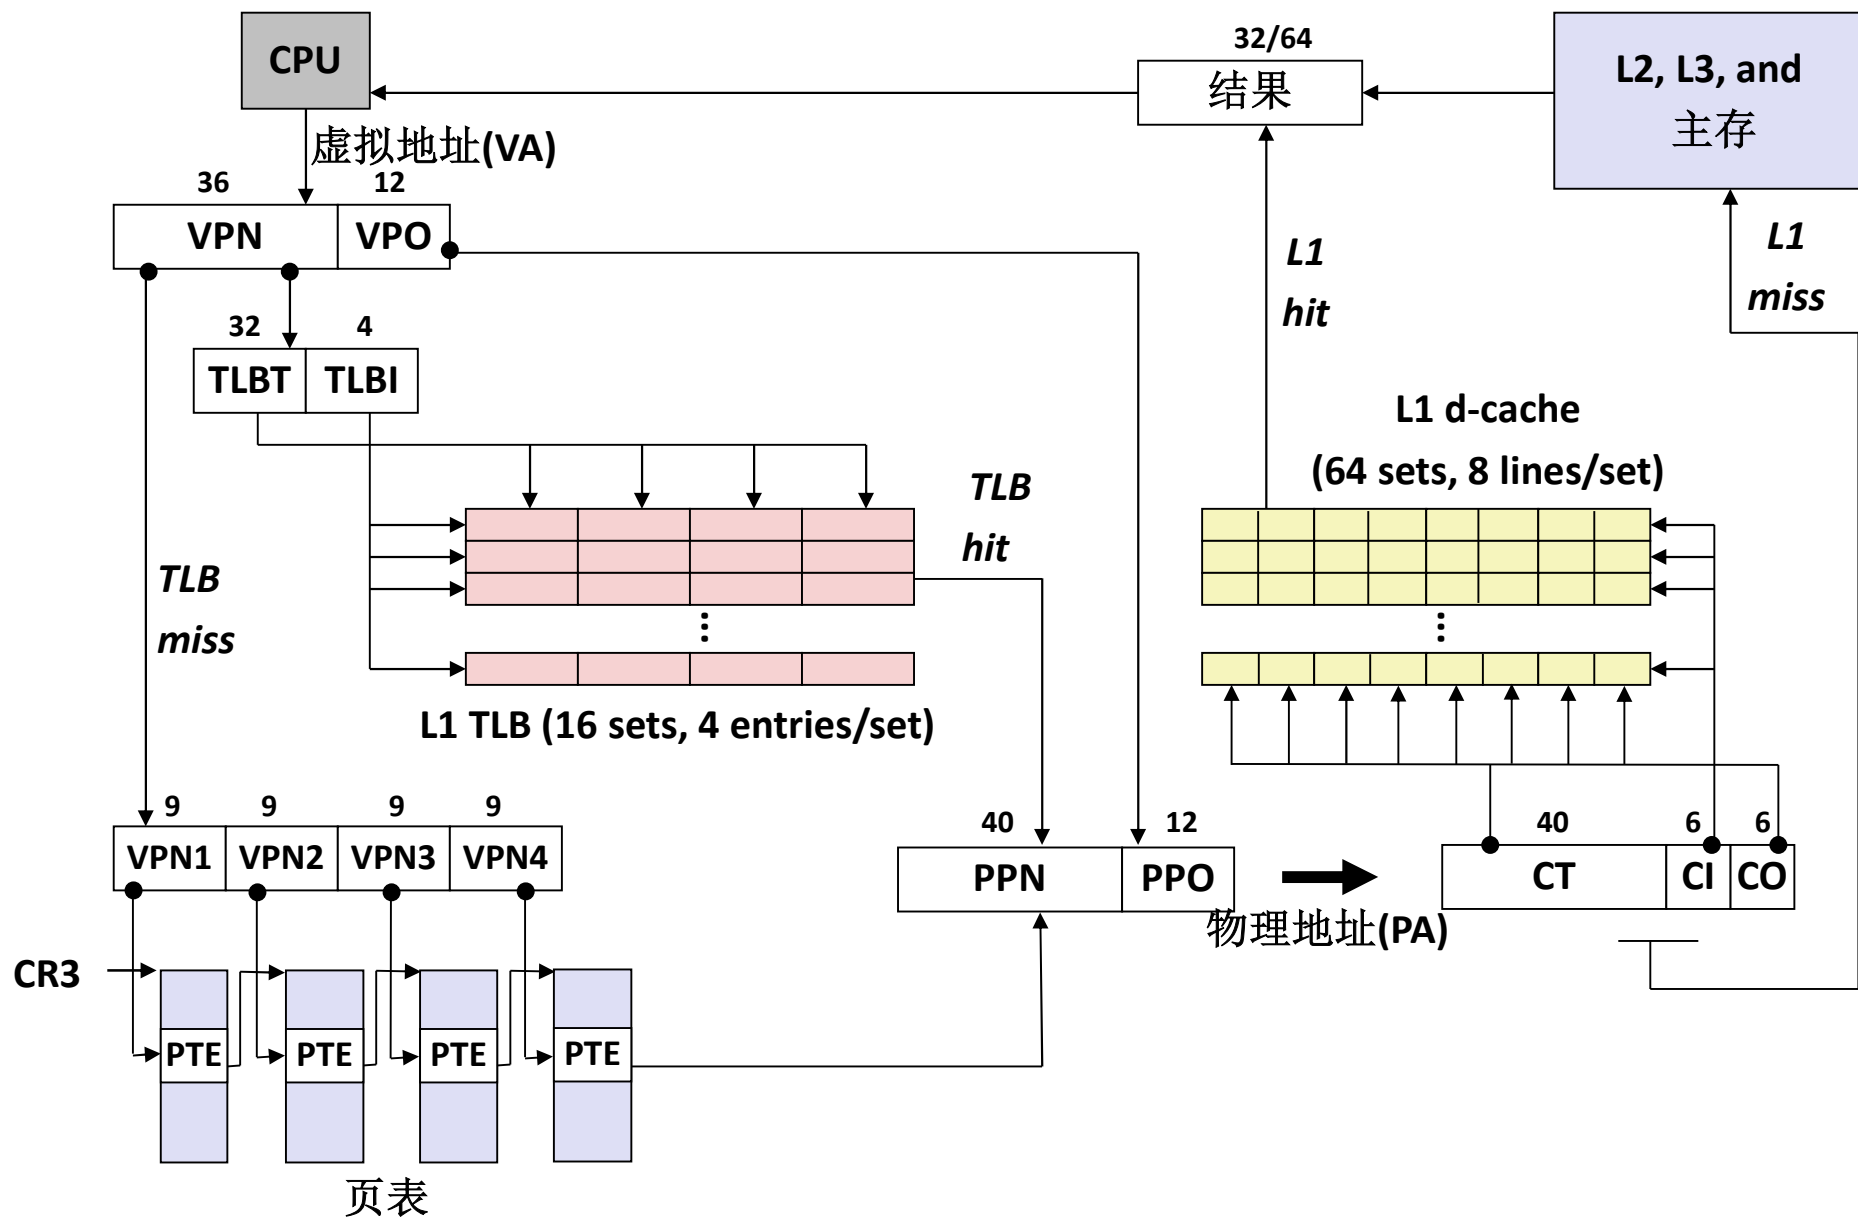
■ 虚拟地址 (VA, Virtual Address) 的组成

- TLBI (TLB Index) : TLB 索引
- TLBT (TLB Tag) : TLB 标签
- VPO (Virtual Page Offset) : 虚拟页偏移
- VPN (Virtual Page Number) : 虚拟页号

■ 物理地址 (PA, Physical Address) 的组成

- PPO (Physical Page Offset) : 物理页偏移, 与虚拟页偏移 VPO 完全相同
- PPN (Physical Page Number) : 物理页号
- CO: Byte offset within cache line, 偏移
- CI: Cache index
- CT: Cache tag

端到端Core i7 地址翻译简化概况



Core i7 第1-3级页表条目格式

| | | | | | | | | | | | | | | | |
|-----------------|-----|---------|----|----|----|-----|---|----|---|---|----|----|-----|-----|-----|
| 63 | 62 | 52 | 51 | 12 | 11 | 9 | 8 | 7 | 6 | 5 | 4 | 3 | 2 | 1 | 0 |
| XD | 未使用 | 页表物理基地址 | | | | 未使用 | G | PS | | A | CD | WT | U/S | R/W | P=1 |
| OS可用 (磁盘上的页表位置) | | | | | | | | | | | | | | | P=0 |

每个条目引用一个 4K 子页表。主要字段说明如下：

- P: 指示子页表是否存在于物理内存中。1 表示存在，0 表示不存在。
- R/W: 为所有可访问页面设置读写权限。只读或读写。
- U/S: 为所有可访问页面设置用户模式或特权（内核）模式的访问权限。
- WT: 子页表的缓存策略，选择直写（Write-through）或回写（Write-back）。
- A: 引用位（Reference bit），由 MMU 在读写操作时自动设置，软件可清零。
- PS: 页面大小，4KB 或 4MB（仅在一级页表项中定义）。
- 页表物理基址: 物理页表地址的最高 40 位，强制页表按 4KB 对齐。
- XD: 禁止或允许从该页表项可访问的所有页面中取指令。

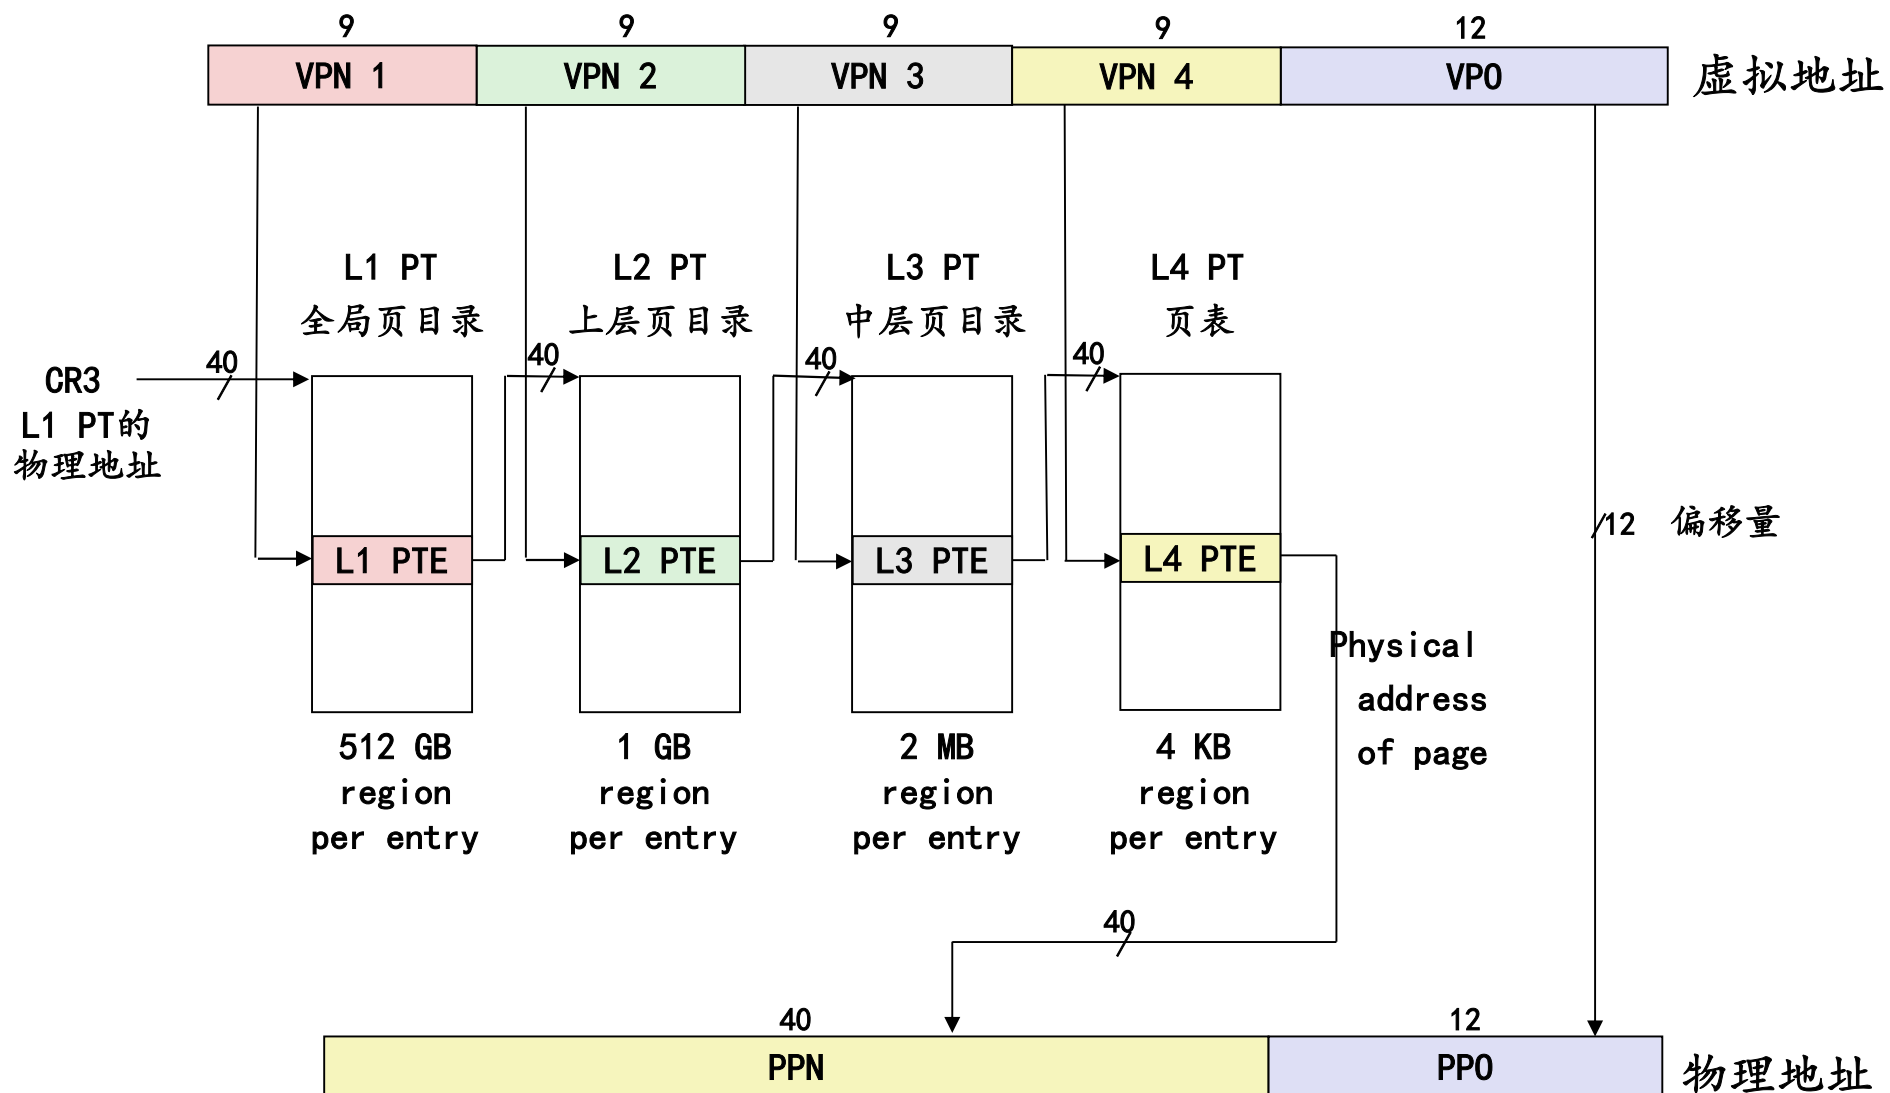
Core i7 第4级页表条目格式

| 63 | 62 | 52 | 51 | 12 | 11 | 9 | 8 | 7 | 6 | 5 | 4 | 3 | 2 | 1 | 0 |
|-----------------|-----|---------|----|----|----|-----|---|---|---|---|----|----|-----|-----|-----|
| XD | 未使用 | 页表物理基地址 | | | | 未使用 | G | | D | A | CD | WT | U/S | R/W | P=1 |
| OS可用 (磁盘上的页表位置) | | | | | | | | | | | | | | | P=0 |

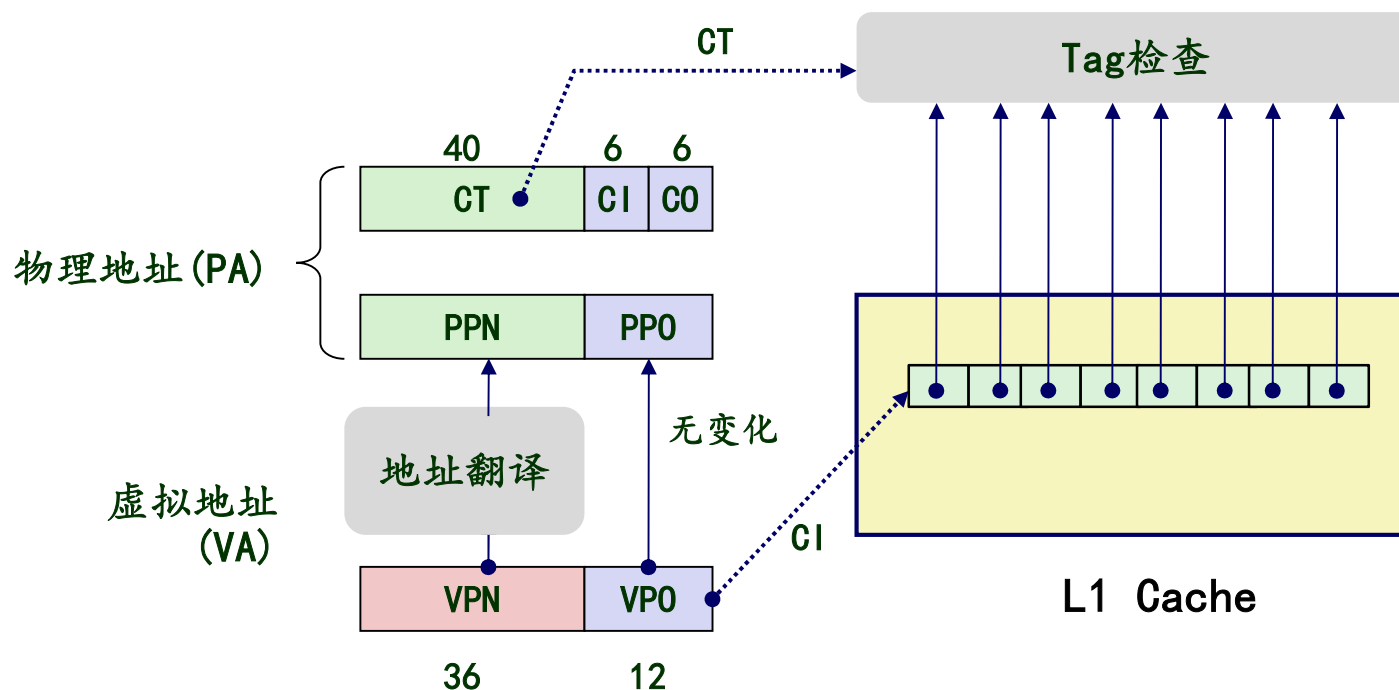
每个条目引用一个 4K 子页面。主要字段说明如下：

- P: 指示子页面是否存在于物理内存中。1 表示存在，0 表示不存在。
- R/W: 对子页面的读写权限控制，可设为只读或读写。
- U/S: 用户模式或特权（内核）模式的访问权限控制。
- WT: 此页面的缓存策略，选择直写（Write-through）或回写（Write-back）。
- A: 引用位（Reference bit），由 MMU 在读写操作时自动设置，软件可清零。
- D: 脏位（Dirty bit），由 MMU 在写操作时自动设置，软件可清零。
- 页面物理基址: 物理页面地址的最高 40 位，强制页面按 4KB 对齐。
- XD: 禁止或允许从该页面中取指令。

Core i7 页表地址翻译



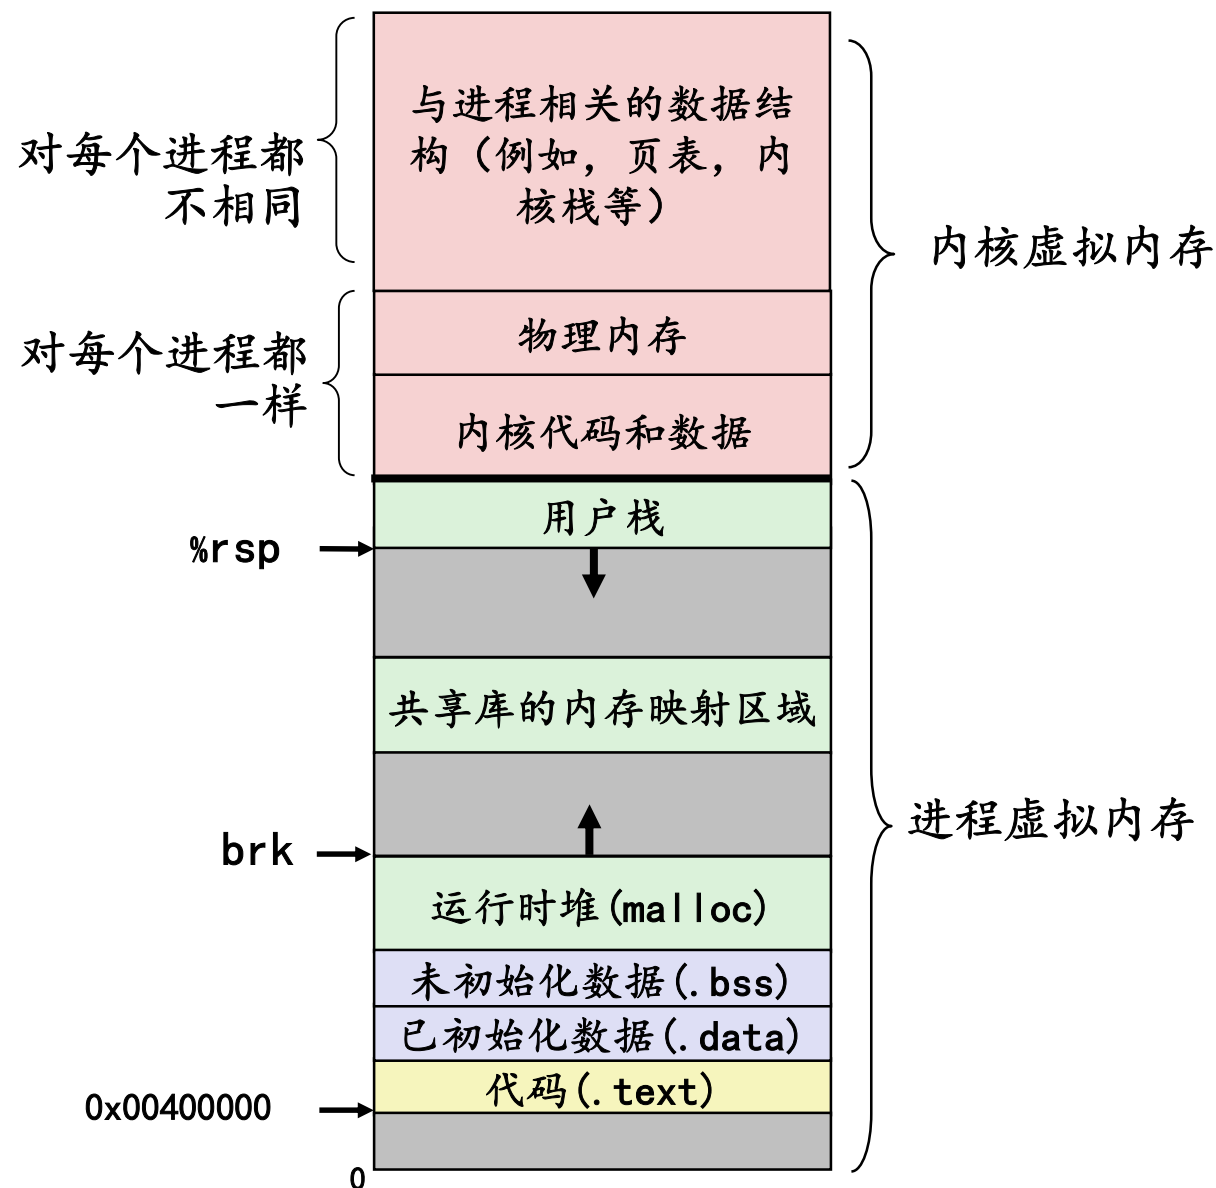
加速 L1 访问的技巧




■ 观察:

- 确定在虚拟地址和物理地址中相同的缓存索引 (CI) 位
- 在地址转换的同时就可以用这些位索引缓存
- 通常会命中TLB, 因此 物理页号 (PPN) 中的高位 (即 CT bits) 很快可得。
- “虚拟索引, 物理标记” 缓存
- 缓存需要精心设计大小, 以确保上述方法可行。

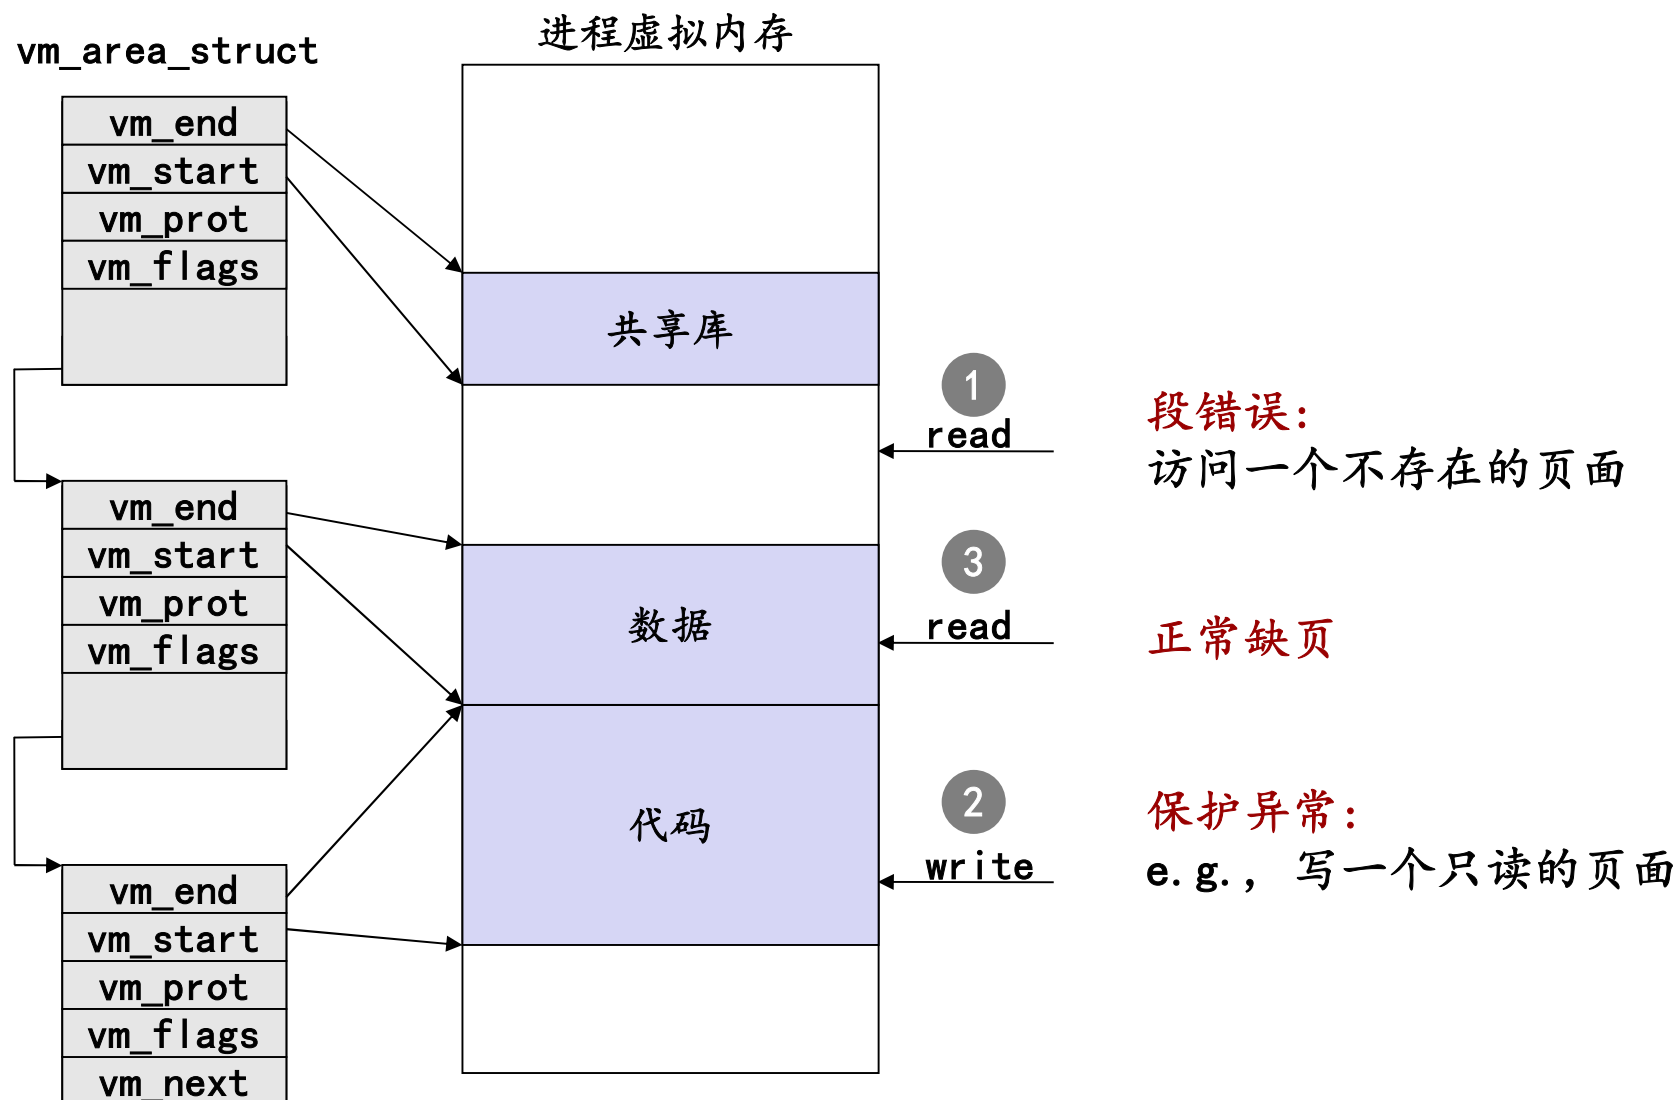
一个Linux进程的虚拟内存



Linux将虚拟内存组织为区域的集合



Linux缺页处理




主要内容

- 简单内存系统示例
- 案例研究：Core i7/Linux 内存系统
- Linux内存映射

Linux 内存映射 (Memory Mapping)

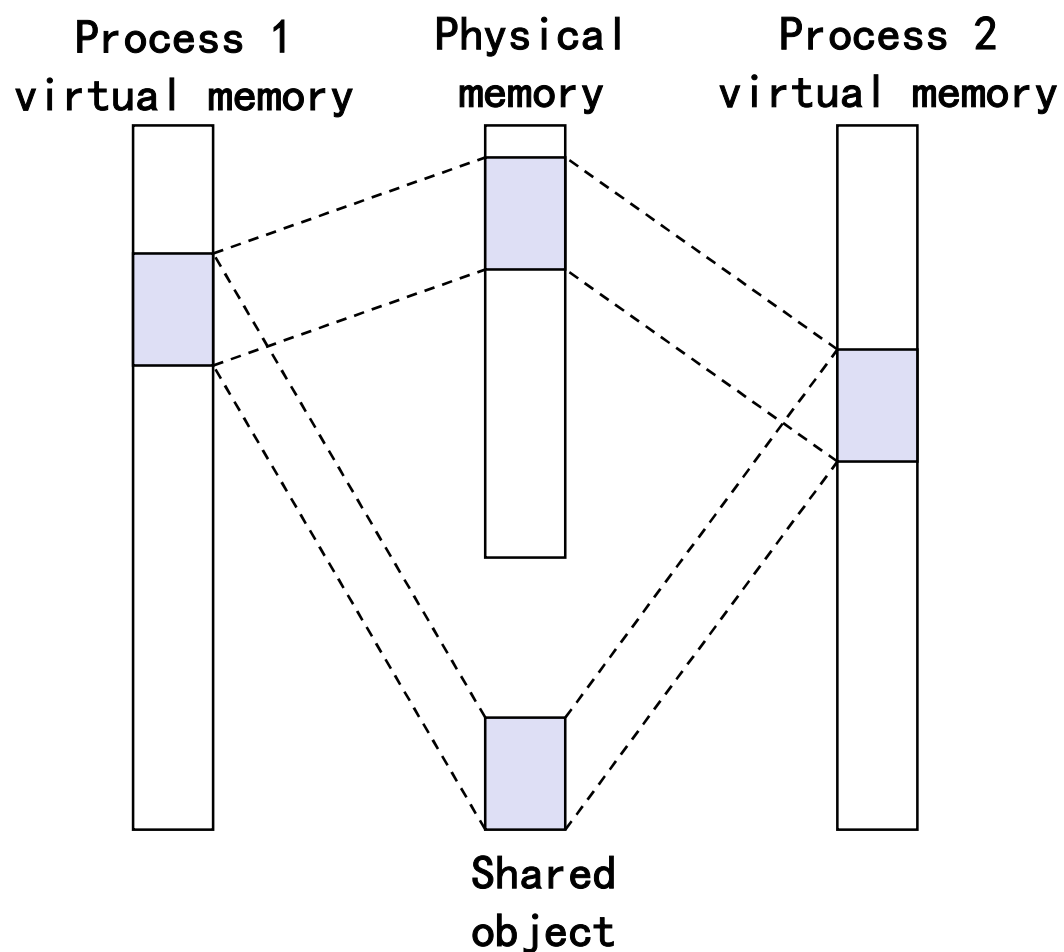
- 虚拟内存区域 (VM areas) 通过与磁盘对象关联来初始化。
 - 这个过程称为 内存映射 (memory mapping) 。
- 内存区域可以由以下来源支持 (也就是初始值来自哪里) :
 - 普通文件 (Regular file) : 例如磁盘上的可执行文件。
 - 初始页的内容来自文件的某一部分。
 - 匿名文件 (Anonymous file) : 例如什么也没有。
 - 第一次缺页 (page fault) 时, 系统会分配一个全是 0 的物理页 (称为 需求零页 demand-zero page) 。
 - 一旦该页被写入数据 (变脏, dirtied) , 它就和普通页面一样。
- 脏页 (Dirty pages) 会在内存与一个特殊的交换文件 (swap file) 之间来回拷贝。

共享对象 (Shared Objects)



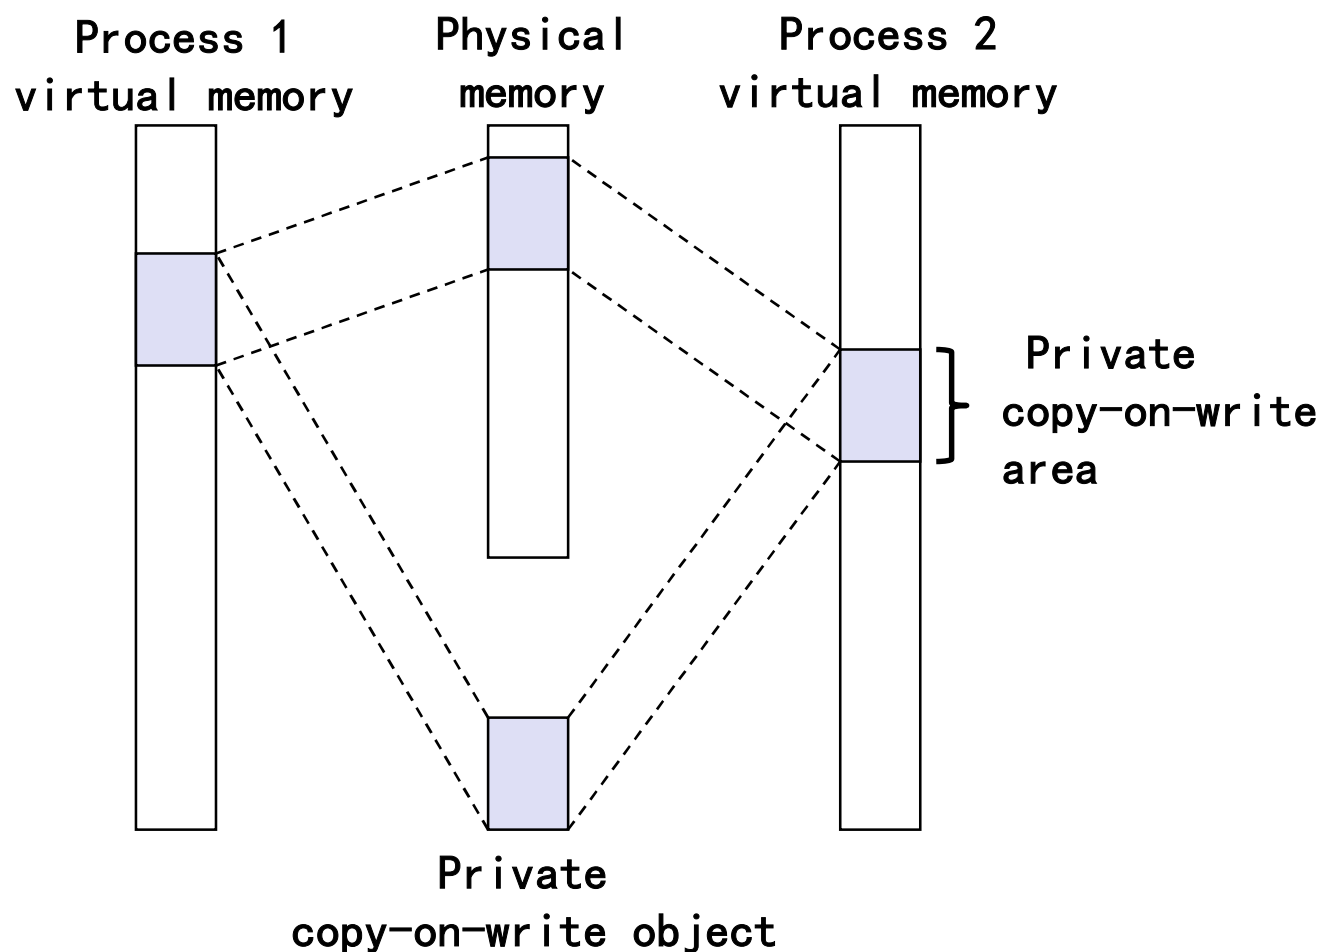
- 进程1通过虚拟内存映射到一块存放了共享对象的物理内存。

共享对象 (Shared Objects)




- 进程2也映射到了同一个共享对象。
- 注意：进程1和进程2虽然在虚拟地址空间中访问的是不同的虚拟地址，但实际上它们指向同一块物理内存。

写时复制 (Copy-On-Write, COW)



- 两个进程映射一个私有写时复制 (COW) 对象。
- 标记为私有写时复制的区域
- 私有区域中的 PTE 被标记为只读

写时复制 (Copy-On-Write, COW)



- 写入私有页面的指令触发保护错误。
- 处理程序创建新的读/写页面。
- 处理程序返回后，指令重新启动。
- 复制操作尽可能延迟！

fork 是什么

- fork 是 Unix/Linux 操作系统里最经典的 系统调用 (system call) 之一。
- 它的功能是：创建一个新进程（也叫子进程），几乎是父进程的完整拷贝。名字来自英文的 fork，意思是“分叉”。
- 执行 fork() 后，程序的执行路径就像树枝一样分成两条：一条是父进程继续往下走，一条是子进程开始执行。

exec 是什么

- `exec` 是另一类系统调用的统称（包括 `execl`、`execv`、`execve` 等），它的功能是：用一个新程序替换当前进程的内容。
- 调用 `exec` 之后，当前进程的内存空间（代码段、数据段、堆、栈等）会被清空，加载磁盘上的新程序，然后从新程序的入口开始执行。
- 注意：`exec` 并不创建新进程，而是“改造”当前进程。进程 ID (PID) 不会变，但进程里运行的代码和数据已经完全变了。

什么是系统调用

- 系统调用是用户态程序进入内核、请求内核服务的唯一正规入口。
- 用户态不能直接碰硬件或内核数据结构（为安全与稳定），于是内核公开一小撮“门”，比如 `read/write/open/fork/exec/mmap/socket` 等，程序只能通过这些门办事。
- `fork()`、`execve()` 从哪儿来：
 - 提供者：操作系统内核（Linux 内核）。
 - 语言里的函数：通常由标准库做“包装”（Linux 上多为 `glibc`）。你在 C 里调 `fork()`、`execve()`、`read()`，其实是调用 `glibc` 的薄封装，它再把请求递交给内核。
 - 内核里的实现：对应到具体内核函数，例如 `do_fork()`、`do_execve()`、`__x64_sys_read()` 等。

都有哪些系统调用

- 进程/线程: fork, vfork, clone, execve, wait, exit, setpriority
- 内存管理: mmap/munmap, brk, mprotect, madvise
- 文件/目录: openat, read, write, close, stat, link/unlink, rename, fsync
- I/O 复用: select, poll, epoll_*
- IPC: pipe, shmget/shmat (SysV), mmap (匿名共享), sem, msg*
- 网络: socket, bind, listen, accept, connect, send/recv, getsockopt/setsockopt
- 时间/定时器: clock_gettime, nanosleep, timerfd
- 同步/调度: futex, sched_*, yield
- 安全/命名空间: setuid/setgid, capset, chroot, unshare, setns, seccomp
- 其他: ioctl (设备控制), getrandom, uname

这个示例小内存系统的一个快照

- 包括TLB、页表的一部分，高速缓存。
- 在TLB和高速缓存的图上面，我们还展示了访问这些设备时硬件是如何划分虚拟地址和物理地址的位的。

